10. Prediction trước experiment

Dataset: SMS Spam Collection

Prediction 1 - Do các từ hoặc cụm từ đặc trưng của spam có thể xuất hiện thường xuyên hơn trong tin nhắn spam và ít xuất hiện hơn trong tin nhắn thông thường nên TF-IDF có thể giúp biểu diễn sự khác biệt giữa 2 lớp. Logistic Regression có thể học từ những đặc trưng này để phân loại tin nhắn. Vì vậy, TF-IDF + Logistic regression có khả năng hoạt động tốt cho bài toán phân loại spam.

Prediction 2 - Average Word2Vec chưa chắc tốt hơn TF-IDF vì hiệu quả phụ thuộc vào đặc điểm và chất lượng của dataset. Average Word2Vec có thể làm mất thông tin quan trọng khi lấy trung bình các vectơ từ, trong khi TF-IDF có thể nhấn điểm được các đặc trưng của spam. ~~Vì vậy~~

Prediction 3 - Tăng vocabulary size chưa chắc làm accuracy tăng vì từ điển lớn hơn có thể chứa thêm nhiều từ hiếm hoặc nhiễu. Nếu những từ mới không cung cấp thông tin hữu ích để phân biệt tin nhắn spam tin nhắn thường thì accuracy có thể giữ nguyên hoặc giảm.

Thứ ngày . .

Prediction 4 - Bỏ stopword giúp giảm nhiễu nhưng cũng có thể làm mất thông tin quan trọng để phân loại tiếng nhắn. Do đó bỏ stopword chưa chắc đã làm performance tăng.

Prediction 5 - Accuracy và F1 có thể đưa ra kết luận khác nhau, đặc biệt khi dataset bị mất cân bằng giữa các lớp. Accuracy có thể cao dù mô hình phân loại kém lớp thiểu số, trong khi F1 kết hợp giữa Precision và Recall để đánh giá khả năng nhận diện lớp đó. Điều đó dẫn đến việc F1 nhạy hơn và phản ánh hiệu quả phân loại spam tốt hơn Accuracy trong 1 số trường hợp.